



JITE (Journal of Informatics and Telecommunication Engineering)

Available online <http://ojs.uma.ac.id/index.php/jite> DOI : 10.31289/jite.v6i1.6751

Received: 09 February 2022

Accepted: 07 July 2022

Published: 23 July 2022

Liver Segmentation Using Convolutional Neural Network Method with U-Net Architecture

Muhammad Awaludin Djohar¹⁾, Anita Desiani¹⁾*, Ali Amran¹⁾, Sugandi Yahdin¹⁾, Dewi Lestari Dwi Putri¹⁾, Des Alwine Zayanti¹⁾, Novi Rustiana Dewi¹⁾

¹⁾ Jurusan Matematika Fakultas MIPA, Universitas Sriwijaya Indonesia

Corresponding Email*: anita_desiani@unsri.ac.id

Abstrak

Kelainan pada liver atau hati dapat digunakan untuk mengenali terjadinya gangguan pada hati salah satunya adalah kanker hati. Untuk mendeteksi kelainan pada liver perlu dilakukan segmentasi untuk mengambil bagian dari hati yang mengalami gangguan. Segmentasi pada hati biasanya dilakukan secara manual dengan rontgen sinar x. Deteksi manual ini cukup memakan waktu untuk mendapatkan hasil analisisnya. Segmentasi merupakan salah satu teknik dalam proses pengolahan citra yang mengalokasikan citra menjadi objek dan latar. Penerapan deep learning dapat digunakan dalam membantu segmentasi citra medis. Salah satu metode deep learning yang banyak digunakan untuk segmentasi adalah U-Net CNN. U-Net CNN memiliki dua bagian encoder dan decoder yang digunakan untuk segmentasi citra. Penelitian ini menerapkan U-Net CNN untuk melakukan segmentasi pada citra data hati. Hasil kinerja dari penerapan U-Net CNN pada citra hati sangat baik. Kinerja akurasi yang diperoleh adalah 99%, sensitivitas adalah 99%. Spesifisitas adalah 99%, F1-Score 98% Koefisien Jacard 96.46% dan DSC adalah 98%. Kinerja yang dicapai dari penerapan U-Net CNN rata-rata di atas 95% hal ini dapat disimpulkan penerapan U-Net CNN sangat baik dan kuat dalam melakukan segmentasi kelainan pada hati. Penelitian ini hanya membahas mengenai segmentasi pada citra hati. Hasil yang diperoleh belum diterapkan pada klasifikasi jenis gangguan yang ada pada hati. Penelitian selanjutnya dapat diterapkan hasil segmentasi dari penerapan U-Net CNN dalam masalah klasifikasi jenis gangguan pada hati.

Kata Kunci: Segmentasi, U-Net, Hati, CNN, Klasifikasi

Abstract

Abnormalities in the liver can be used to identify the occurrence of disorders of the liver, one of which is called liver cancer. To detect abnormalities in the liver, segmentation is needed to take part of the liver that is affected. Segmentation of the liver is usually done manually with x-rays. This manual detection is quite time consuming to get the results of the analysis. Segmentation is a technique in the image processing process that allocates images into objects and backgrounds. Deep learning applications can be used to help segment medical images. One of the deep learning methods that is widely used for segmentation is U-Net CNN. U-Net CNN has two parts encoder and decoder which are used for image segmentation. This research applies U-Net CNN to segment the liver data image. The performance results of the application of U-Net CNN on the liver image are very good. Accuracy performance obtained is 99%, sensitivity is 99%. The specificity is 99%, the F1-Score is 98%, the Jacard coefficient is 96.46% and the DSC is 98%. The performance achieved from the application of U-Net CNN on average is above 95%, it can be concluded that the application of U-Net CNN is very good and robust in segmenting abnormalities in the liver. This study only discusses the segmentation of the liver image. The results obtained have not been applied to the classification of types of disorders that exist in the liver yet. Further research can apply the segmentation results from the application of U-Net CNN in the problem of classifying types of liver disorders.

Keywords: Segmentation, U-Net, Liver, CNN, Classification

How To Cite: Djohar, M. A., Desiani, A., Amran, A., Yahdin, S., Putri, D. L., Zayanti, D. A., & Dewi, N. R. (2022). Liver Segmentation Using Convolutional Neural Network Method with U-Net Architecture. *JITE (Journal of Informatics and Telecommunication Engineering)*, 6(1), 221-234.

I. PENDAHULUAN

Hati adalah salah satu organ tubuh manusia yang terletak di sisi sebelah kanan atas rongga perut (Rela et al., 2020). Hati bertanggung jawab untuk mencerna, menyerap, dan memproses makanan serta berfungsi untuk menyaring darah dari saluran pencernaan sebelum dibawa ke bagian organ tubuh lainnya (Rosida, 2016). Dengan fungsinya yang kompleks dan sangat penting, organ hati harus dijaga kesehatannya, karena organ tersebut rentan terhadap penyakit (Falatehan et al., 2018). Salah satu penyakit yang berbahaya dan sering menyerang organ hati adalah kanker hati. Kanker hati merupakan penyakit yang disebabkan oleh pertumbuhan sel-sel ganas di hati yang tidak terkendali (Latifatul Khairiah, Tursina, 2017). Pada tahun 2020, Global Cancer Statistic melaporkan bahwa lebih dari 900.000 orang di dunia terkena penyakit kanker hati dan lebih dari 830.000 orang meninggal dunia dikarenakan kanker hati (Sung et al., 2021). Untuk itu diperlukan pencegahan dan deteksi sejak dini agar kondisi tersebut tidak semakin parah.

Selama ini, dokter dan ahli radiologi masih melakukan deteksi penyakit pada hati secara manual menggunakan teknik rontgen pada bagian hati. Hasil yang didapatkan dari teknik rontgen ini ialah data citra hati. Namun, pada data citra hati tersebut masih terdapat bagian-bagian lain seperti ginjal, empedu, dan pankreas (Rela et al., 2020). Bagian-bagian lain ini akan mengganggu proses deteksi penyakit pada hati. Sehingga dibutuhkanlah suatu sistem yang bisa mendapatkan bagian hati saja secara otomatis agar mempermudah dokter dan ahli radiologi dalam mendiagnosa penyakit pada hati (Alalwan et al., 2021). Teknik yang umum dilakukan adalah melakukan rontgen dengan sinar x pada bagian hati (liver) pasien, data citra yang dihasilkan dari teknik ini disebut dengan citra hati atau liver. Akan tetapi pada citra hati terdapat bagian-bagian lain seperti limpa, ginjal, pankreas, aorta, dan perut (Triwoto & Sardjono, 2015), bagian-bagian lain ini akan mengganggu proses deteksi penyakit pada hati, sehingga diperlukan proses yang disebut segmentasi. Beberapa penelitian telah dilakukan dalam segmentasi hati antara lain : Anter & Hassenian (2019) melakukan segmentasi hati menggunakan metode neutrosophic sets, fast fuzzy c-means and adaptive watershed algorithm (NS-WS-FFCM) dengan menghasilkan nilai jaccard sebesar 86,84% dan dice similarity coefficient (DSC) sebesar 92,88%. Penelitian lain juga telah dilakukan oleh Cai (2019) dengan menggunakan metode Adaptive Scale-Kernel Fuzzy Clustering menghasilkan nilai DSC sebesar 87,02%. Pada penelitian yang dilakukan Anter & Hassenian (2019), nilai DSC sudah sangat baik, namun untuk nilai jaccard nya masih dibawah 90%, serta tidak menghitung kinerja lainnya. Pada penelitian yang dilakukan oleh Cai (2019), nilai DSC nya masih dibawah 90% serta tidak menghitung kinerja lainnya. Hal ini disebabkan metode segmentasi yang digunakan merupakan metode konvensional yang belum mampu membedakan suatu objek dengan objek lainnya secara akurat, karena metode konvensional hanya mempelajari representasi fitur secara dangkal (Wang & Deng, 2018). Untuk mengatasi hal tersebut, maka diperlukan metode lain yang dapat mempelajari representasi fitur secara mendalam untuk mendapatkan hasil segmentasi yang akurat.

Salah satu metode yang berkembang pada saat ini adalah deep learning. Deep learning menjadi topik yang banyak digunakan saat ini dalam berbagai bidang salah satunya dalam melakukan segmentasi. Segmentasi merupakan suatu teknik dalam proses pengolahan data gambar dengan cara mengalokasikan citra ke dalam beberapa field yang berbeda, yaitu objek yang diteliti dan background (Desiani et al., 2021). Metode yang sering digunakan dalam melakukan segmentasi gambar adalah Convolutional Neural Networks (CNN) yang telah digunakan untuk banyak permasalahan dalam visi komputer. CNN memperoleh kinerja yang luar biasa pada tugas yang berbeda seperti pengenalan objek visual, klasifikasi gambar, pengenalan sepuluh karakter tulisan tangan dan masih banyak lagi (Bilic et al., 2019). Convolutinal Neural Network (CNN) telah berkembang dan menunjukkan kemampuan yang baik dalam analisa citra (Xie et al., 2017). Salah satu arsitektur dari CNN yang banyak digunakan untuk melakukan segmentasi ialah arsitektur U-Net.

Arsitektur U-Net memiliki dua jalur yaitu jalur encoder dan jalur decoder. Proses jalur encoder digunakan untuk pengurangan ukuran matriks input sedangkan jalur decoder digunakan untuk mengembalikan ukuran matriks ke ukuran semula dengan meminimalkan jumlah feature maps sehingga gambar bisa tersegmentasi (Pravitasari et al., 2020). Beberapa penelitian yang menggunakan arsitektur U-Net dalam segmentasi citra antara lain: Penelitian oleh (Pranata et al., 2022) dalam segmentasi paru-paru menghasilkan nilai akurasi 91,68%, sensitivitas 92,80%, spesifisitas 89,15%, dan f-1 score sebesar 93,92%. Selanjutnya penelitian yang dilakukan oleh (He et al., 2018) dalam segmentasi lesi kulit menghasilkan nilai akurasi 96%, DSC 93,1%. Kemudian penelitian lain yang dilakukan oleh (Saeedizadeh et al., 2021) dalam segmentasi ct dada untuk covid-19 menghasilkan nilai sensitivitas 80,8%, spesifisitas 96%, dan DSC 80,1%. Pada penelitian (Pranata et al., 2022) dalam segmentasi paru-paru nilai spesifisitas yang diperoleh cukup baik, namun masih dibawah 90%. Sedangkan pada penelitian (He et al., 2018) dalam segmentasi lesi kulit nilai akurasi dan DSC sudah sangat baik diatas 90%, namun tidak tidak menghitung nilai evaluasi kinerja

yang lain seperti sensitivitas, spesifisitas, jaccard dan f-1 score. Pada penelitian (Saeedizadeh et al., 2021) dalam segmentasi ct dada, nilai akurasi yang diperoleh sudah sangat baik, namun nilai sensitivitas dan DSC yang diperoleh masih dibawah 90%. Namun demikian, penelitian mendalam untuk mendapatkan hasil citra lebih baik pada citra hati masih dibutuhkan dikarenakan pada penelitian sebelumnya yang menggunakan metode konvensional mendapatkan hasil performa yang belum optimal dengan rata-rata nilai masih dibawah 95%. Maka dalam penelitian ini akan dilakukan segmentasi pada data liver atau hati menggunakan metode CNN arsitektur U-Net yang merupakan jaringan syaraf convolutional yang dikembangkan untuk segmentasi citra.

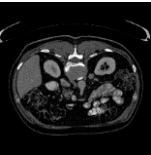
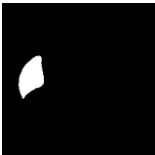
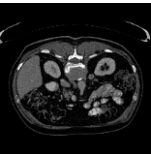
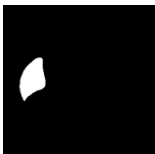
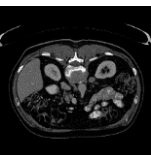
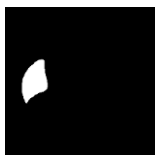
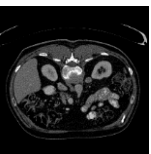
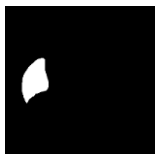




Dari ketiga penelitian tersebut menunjukkan bahwa kemampuan kinerja arsitektur U-Net sudah cukup baik dalam melakukan segmentasi. Sehingga, pada penelitian ini akan dilakukan segmentasi citra hati menggunakan arsitektur U-Net, dimana evaluasi kinerja model yang diukur yaitu akurasi, sensitivitas, spesifisitas, koefisien jaccard, dan DSC.

II. METODE PENELITIAN

A. Deskripsi Data

Data yang digunakan dalam penelitian ini merupakan data sekunder yang bersumber dari database kaggle.com dengan website <https://www.kaggle.com/markdants/liver-dataset>. Data yang digunakan berjumlah 800 citra yang terbagi menjadi 400 citra *liver* dan 400 *ground truth*.

Tabel 1. Sampel Dataset Liver Mark_dants

Nama Citra	Citra Liver	Ground Truth
001.png		
002.png		
003.png		
004.png		
005.png		
006.png		

B. Split Data

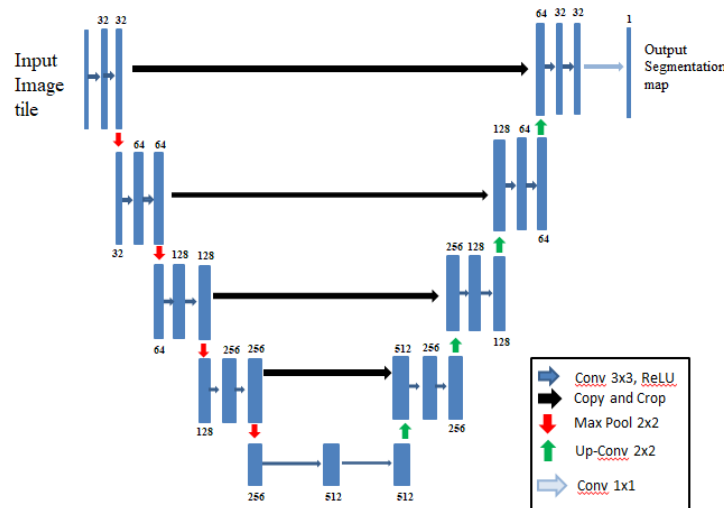
Split data merupakan proses pembagian data input yang akan digunakan dalam menguji kinerja arsitektur. Data yang dimiliki sebanyak 400 data akan di split menjadi data training, data validasi dan data testing dengan pembagian sebesar 80% atau sebanyak 320 untuk data training, 10% atau sebanyak 40 untuk data validasi dan 10% atau sebanyak 40 untuk data testing.

C. Convolutional Neural Networks (CNN)

CNN atau *Convolutional Neural Network* merupakan jaringan saraf yang tersusun atas *convolution layer* dan *fully connected layer*. Fungsi *convolutional layer* adalah tempat untuk mengekstrak karakteristik *input* yang masuk. *Convolutional layer* memiliki lapisan fungsi aktivasi dan *pooling layer* yang berfungsi untuk seleksi serta *filtering input* yang telah di proses *convolutional layer*. *Fully connected layer* merupakan bagian akhir dari *hidden layer* pada CNN yang berfungsi sebagai tempat klasifikasi sampel berdasarkan fitur yang diekstraksi (Zhou et al., 2020).

D. U-Net

U-Net merupakan salah satu varian arsitektur dari CNN yang banyak digunakan untuk segmentasi dalam bidang medis (Siddique et al., 2021). *U-Net* memiliki 2 bagian utama yaitu *contracting path (encode)* untuk mengambil fitur *input* dan menciptakan dimensi yang lebih kecil dari *input* dan *expansive path* untuk mengambil fitur hasil *encode* dan memberikan kecocokan terbaik dengan *input* utama atau *output* yang direncanakan (Popat et al., 2020). Gambar arsitektur dasar *U-Net* dapat dilihat pada Gambar 1 (Popat et al., 2020).



Gambar 1 Arsitektur U-Net

Berdasarkan Gambar 1, data di *input* akan melewati jalur *encode* pada *U-Net* yang terdiri dari empat convolutional block, dimana dilakukan proses konvolusi 3X3 pada *convolutional layer* dengan menggunakan Persamaan (1), kemudian dilakukan aktivasi ReLU, dan diakhiri dengan *Max Pooling 2X2*. Kemudian dilakukan konvolusi 3X3 dan ReLU sebanyak tiga kali. Terakhir jalur *decode* yang terdiri dari 4 *convolutinal upsampling block*, dilakukan proses *upsampling* yaitu *transposed convolutional 2X2*, *concatenate*, konvolusi 3X3, dan ReLU. Pada tahap akhir *decode* digunakan fungsi aktivasi sigmoid.

E. Convolutional layer

Merupakan inti utama dalam proses dasar CNN yang melakukan operasi konvolusi pada *output layer* sebelumnya. Lapisan ini terdiri dari satu set kernel konvolusional untuk mengekstraksi fitur lokal dari *input* (Guo et al., 2017). Untuk menghitung proses konvolusi, digunakan persamaan berikut:

$$c_{i,j} = \left(\sum_{u=0}^{n-1} \sum_{v=0}^{n-1} a_{u+i,v+j} \times k_{i+1,j+1} \right) + b_q \quad (1)$$

di mana i menyatakan baris, j menyatakan kolom, n adalah ukuran tinggi kernel, A_p merupakan matriks *input* ke- p , K_q adalah matriks kernel ke- q , b_q adalah bias untuk kernel ke- q .

F. Pooling Layer

Pooling layer mengambil blok dari *convolutional layer* dan sampel mereka untuk menghasilkan satu *output* maksimum yang bertujuan untuk mengurangi dimensi *feature maps* yang diperoleh pada proses *convolutional layer* (Es-Sabery et al., 2021; Shamsaldin et al., 2019). *Pooling layer* terbagi menjadi 2 metode, yaitu *Max Pooling* (nilai maksimum) dan *Average Pooling* (nilai rata-rata). Pada penelitian ini, metode yang digunakan adalah *Max Pooling*.

G. Rectified Linear Unit (ReLU)

ReLU adalah fungsi aktivasi yang mengatur ulang semua nilai negatif ke nol sambil menjaga nilai positif tidak berubah. ReLU sering ditambahkan dalam tahap *convolution layer* dan *pooling layer*. Persamaan ReLU dapat dilihat pada persamaan (2) berikut.

$$f(x) = \max(0, x) \begin{cases} 0, & \text{untuk } x < 0 \\ x, & \text{untuk } x \geq 0 \end{cases} \quad (2)$$

Dengan $f(x)$ adalah hasil fungsi aktivasi ReLU dan x merupakan nilai *input*. Representasi fungsi ReLU dapat dilihat pada Gambar 2.



Gambar 2 Representasi Grafik Fungsi ReLU

Pada Gambar 2 dapat dilihat bahwa fungsi aktivasi ReLU menghasilkan nilai *output* 0 ketika nilai *input* lebih kecil dari 0, dan menghasilkan linear dengan kemiringan 1 ketika *input* lebih besar dari 0.

H. Transposed Convolution

Transposed convolution merupakan lapisan *upsampling* yang dapat dilihat sebagai konvolusi terbalik dalam arti bagaimana *input* dan *output* saling berhubungan. *Transposed convolution* setara dengan menyisipkan fitur dengan 0 dan menerapkan operasi konvolusi standar pada prosesnya.

I. Concatenate

Concatenate digunakan untuk menggabungkan dua buah matriks *input* dari dua peta fitur menjadi satu buah matriks *input* baru yang memiliki ukuran yang baru. Pada arsitektur *U-Net*, *concatenate* digunakan untuk menggabungkan *feature maps* pada jalur *encode* dan *decode* menjadi satu.

J. Fungsi Aktivasi Sigmoid

Fungsi aktivasi sigmoid (σ) merupakan fungsi yang sering digunakan dalam CNN yang membutuhkan nilai *output* yang terletak pada interval 0 sampai 1 atau *outputnya* 0 dan 1. Persamaan fungsi aktivasi sigmoid dapat dilihat pada Persamaan (3) (Soomro et al., 2019) sebagai berikut :

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (3)$$

dimana $z \in (-\infty, \infty)$, $\sigma(z) \in (0,1)$.

K. Binary Cross Entropy

Binary cross entropy merupakan loss function yang digunakan dalam tugas klasifikasi biner. *Binary cross entropy* dapat dihitung menggunakan Persamaan (4) sebagai berikut (Lian et al., 2019):

$$L = -\frac{1}{m \times n} \left[\sum_{i=1}^m \sum_{j=1}^n (y_{ij} \log(p_{ij}) + (1 - y_{ij}) \log(1 - p_{ij})) \right] \quad (4)$$

dimana $m \times n$ menunjukkan ukuran matriks hasil prediksi segmentasi, y_{ij} merupakan entri matriks label *ground truth* pada baris ke- i kolom ke- j (0 untuk piksel *background* dan 1 untuk piksel pembuluh darah), dan p_{ij} merupakan entri matriks hasil prediksi segmentasi pada baris ke- i kolom ke- j , dan L adalah nilai *loss fuction binary cross entropy*.

L. Evaluasi Hasil Kinerja

Evaluasi kinerja model pada proses segmentasi citra hati dilakukan dengan menggunakan *confusion matrix*. *Confusion Matrix* merupakan pengukuran performa untuk masalah klasifikasi *machine learning* yang digunakan sebagai basis dalam perhitungan evaluasi kinerja model dalam prediksi yang terdiri dari *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) (Hasnain et al., 2020). Hasil dari metode yang digunakan dalam segmentasi citra hati dapat memberikan kesimpulan tentang seberapa baik kinerja model arsitektur *U-Net* dalam segmentasi hati. Kinerja yang diukur dan digunakan dalam penelitian ini adalah sebagai berikut:

1. Akurasi

Akurasi merupakan tingkat keakuratan arsitektur dalam melakukan segmentasi dengan benar. Perhitungan akurasi didefinisikan pada Persamaan 5 berikut (Sule & Viriri, 2020).

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN} \times 100\% \quad (5)$$

2. Sensitivitas

Sensitivitas merupakan tingkat kemampuan arsitektur dalam memprediksi piksel hati dengan benar. Perhitungan sensitivitas didefinisikan pada Persamaan 6 berikut (Qummar et al., 2019).

$$Sensitifitas = \frac{TP}{TP + FN} \times 100\% \quad (6)$$

3. Spesifisitas

Spesifisitas merupakan tingkat kemampuan arsitektur dalam memprediksi piksel *background* dengan benar. Perhitungan sensitivitas didefinisikan pada Persamaan 7 berikut (Qummar et al., 2019).

$$\text{Spesifisitas} = \frac{TN}{TN + FP} \times 100\% \quad (7)$$

4. Dice Similarity Coefficient (DSC)

Dice Similarity Coefficient (DSC) merupakan ukuran kemiripan atau kesamaan dalam *information retrieval*, dimana DSC digunakan untuk menghitung kombinasi nilai yang telah dihasilkan dari sensitivitas dan spesifisitas. Perhitungan DSC didefinisikan pada Persamaan 8 berikut (Fikri, 2019).

$$\text{DSC} = \frac{2TP}{2TP + FP + FN} \times 100\% \quad (8)$$

5. Koefisien Jaccard

Koefisien jaccard merupakan rasio dari luas irisan dengan luas gabungan antara hasil prediksi segmentasi dengan benar dan *groundtruth*. Perhitungan *koefisien jaccard* didefinisikan pada Persamaan 9 (Fernandez-Moral et al., 2018).

$$\text{Koefisien Jaccard} = \frac{TP}{TP + FP + FN} \times 100\% \quad (9)$$

Nilai akurasi, sensitivitas, spesifisitas, DSC, dan *koefisien jaccard* dapat dikelompokkan dalam beberapa kategori yang dapat dilihat pada Tabel 2 berikut (Mishra et al., 2016)


Tabel 2. Kategori nilai evaluasi kinerja model

Nilai (%)	Kategori
Nilai > 90	Sangat Baik
80 < Nilai ≤ 90	Baik
70 < Nilai ≤ 80	Cukup Baik
60 < Nilai ≤ 70	Kurang Baik
Nilai ≤ 60	Gagal


Tabel 2 menunjukkan 5 kategori untuk nilai evaluasi kinerja model, jika nilai kinerja lebih dari 90% maka model tersebut akan dikategorikan sangat baik, jika nilai kinerja lebih dari 80% dan kurang dari sama dengan 90% maka model tersebut dikategorikan baik, jika nilai kinerja lebih dari 70% dan kurang dari sama dengan 80% maka model tersebut dikategorikan cukup baik, jika nilai kinerja lebih dari 60% dan kurang dari sama dengan 70% maka model tersebut termasuk kategori kurang baik, dan jika nilai suatu kinerja kurang dari sama dengan 60% maka model tersebut termasuk kategori gagal.

III. HASIL DAN PEMBAHASAN

Pada penelitian ini, digunakan arsitektur U-Net untuk melakukan proses segmentasi citra hati. Dalam proses training data, dataset liver yang digunakan dilakukan optimalisasi menggunakan Adam Optimizers lalu digunakan loss function : binary cross entropy untuk memperkirakan nilai loss, membandingkan, dan mengukur hasil training. Grafik loss dan akurasi model yang digunakan dapat dilihat pada Gambar 3 dan Gambar 4. Pada Gambar 3, terlihat grafik nilai akurasi dan val_akurasi yang meningkat menuju 1. Dapat diartikan bahwa model yang digunakan sangat baik dalam mempelajari pola input yang diberikan. Pada Gambar 4, terlihat grafik nilai loss dan val_loss yang semakin kecil dan mendekati nol yang artinya semakin kecil nilai loss maka semakin kecil juga tingkat kesalahan yang dilakukan model dalam mempelajari pola input.



Gambar 3 Grafik Akurasi Model U-Net




Gambar 4 Grafik Loss Model U-Net

Pada Gambar 3 terlihat bahwa grafik nilai akurasi pada data latih dan validasi selama proses *training* meningkat signifikan menuju 1 mulai dari *epoch* ke 7, hal ini menunjukkan bahwa model yang digunakan sudah sangat baik dalam mempelajari pola *input* yang diberikan. Pada Gambar 4, terlihat bahwa grafik nilai *loss* pada data latih dan validasi selama proses *training* semakin menurun pada setiap *epoch* dan mendekati nilai nol yang artinya semakin kecil nilai *loss* maka semakin kecil juga tingkat kesalahan yang dilakukan model dalam mempelajari pola *input*. Hasil dari proses *training* selanjutnya disimpan pada sebuah model, dimana model tersebut akan dilakukan pengujian model arsitektur.

Pengujian model arsitektur merupakan rangkaian proses *testing*, dimana proses ini menggunakan data uji yang telah dibagi dari dataset sebanyak 400 data untuk melihat keakuratan model dalam melakukan prediksi segmentasi citra hati. Beberapa perbandingan citra *input*, *grountruth* dan hasil segmentasi dapat dilihat pada Tabel 3.

Tabel 3. Perbandingan citra input, groundtruth, dan hasil segmentasi

Citra Input	Grountruth	Hasil Segmentasi



Pada Tabel 3, dapat dilihat bahwa hasil segmentasi citra hati menggunakan arsitektur *U-Net* sudah terlihat mirip dengan *groundtruth*. Namun, hasil segmentasi yang didapatkan masih ada beberapa area pada *background* yang terprediksi sebagai hati. Selanjutnya, dari hasil prediksi didapatkan *confusion matrix* yang akan digunakan untuk mengukur hasil kinerja model seperti akurasi, sensitivitas, spesifisitas, koefisien jaccard dan DSC. Nilai dari *confusion matrix* yang didapatkan merepresentasikan jumlah piksel pada hasil segmentasi. *Confusion matrix* yang diperoleh dapat dilihat pada Tabel 4.

Tabel 4. Hasil Confusion matrix dari Tahap Testing

Actual	Predict	
	Liver	Background
Liver	141.957	5.140
Background	61	9.852.843

Berdasarkan Tabel 4, hasil prediksi *liver* didapatkan sebanyak 141.957 piksel diprediksi dengan benar sebagai *True Positive* (TP) dan 5.140 diprediksi sebagai *False Negative* (FN). Sedangkan hasil prediksi *True Negative* (TN) didapatkan sebanyak 9.857.843 piksel diprediksi dengan benar sebagai *background* dan 61 diprediksi sebagai *False Positive* (FP). Nilai yang terdapat pada *confusion matrix* digunakan untuk menghitung nilai akurasi, sensitivitas, spesifisitas, koefisien jaccard dan DSC yang dapat dihitung menggunakan Persamaan (5), (6), (7), (8), dan (9). Sehingga berdasarkan Persamaan (5), (6), (7), (8), dan (9). Berikut hasil kinerja dari arsitektur *U-Net* yang digunakan:

Tabel 5 Kinerja Arsitektur U-Net

Jenis Perhitungan	Rata-rata (%)
Akurasi	99,95
Sensitifitas	99,96
Spesifisitas	99,95
Koefisien Jaccard	96,46
DSC	98,20

Berdasarkan Tabel 5, untuk menilai kinerja model maka dapat diprediksi akurasi data secara keseluruhan pada citra *liver*. Hasil sensitifitas yang didapatkan adalah 99,96% dan spesifisitas adalah 99,95% yang mendefinisikan keberhasilan model dalam menemukan informasi. Koefisien jaccard yang didapatkan adalah 96,46% yang digunakan untuk perbandingan presisi rata-rata dan bobot sensitivitas, juga dapat digunakan sebagai acuan untuk menentukan akurasi. DSC digunakan untuk mengevaluasi area yang beririsan antara hasil prediksi dan ground truth. Terlihat pada Tabel 3, bahwa kinerja arsitektur yang digunakan memiliki hasil diatas 96%. Selanjutnya dilakukan interpretasi hasil dengan membandingkan dengan penelitian yang sudah dilakukan. Adapun perbandingan hasil segmentasi *liver* dengan penelitian lain dapat dilihat pada Tabel 6.

Tabel 6 Perbandingan Hasil Evaluasi Kinerja dengan Penelitian Lain

Metode	Akurasi (%)	Sensitivitas (%)	Spesifisitas (%)	Jaccard (%)	DSC (%)
2DU-Net (Han et al., 2021)	96,2	-	-	-	73,5

U-Net+CycleGAN (Kim & Ye, 2018)	-	88,78	83,56	-	84,7
V-Net+WGAN (Ma et al., 2021)	94	-	-	-	90
H-DenseU-Net (Li et al., 2018)	-	-	-	93	92
Metode yang diusulkan	99,95	99,96	99,95	96,46	98,20

Berdasarkan pada Tabel 6, dapat dilihat bahwa nilai pengukuran performa untuk dataset liver menggunakan metode yang diusulkan memiliki nilai yang paling tinggi pada semua aspek. Dapat dilihat bahwa nilai ini merupakan nilai yang paling baik untuk nilai sensitivitas sebesar 99,96%, koefisien jaccard sebesar 96,46% dan DSC sebesar 98,20% dari penelitian-penelitian sebelumnya. Selain itu, arsitektur yang diusulkan juga menghasilkan nilai akurasi sebesar 99,95% dan spesifisitas sebesar 99,95%. Berdasarkan perbandingan hasil penelitian yang telah dilakukan, dapat dikatakan bahwa metode yang diusulkan telah memberikan kinerja yang optimal dalam segmentasi citra hati. Penelitian ini hanya membahas tentang segmentasi pada liver namun belum pada klasifikasi gangguan kanker serviks. Hasil segmentasi pada penelitian ini dapat digunakan untuk mendeteksi adanya kelainan pada liver seperti kanker. Penelitian selanjutnya dapat memanfaatkan hasil segmentasi pada penelitian ini untuk masalah klasifikasi atau prediksi jenis kelainan yang ada pada liver.

IV. SIMPULAN

Hasil penelitian yang didapatkan sudah sangat baik dalam segmentasi citra liver. Hal ini bisa dilihat dari nilai akurasi, sensitivitas, spesifisitas koefisien jaccard dan DSC yang tinggi. Kemampuan model yang diusulkan untuk segmentasi citra liver sudah sangat baik, dilihat dari akurasi sebesar 99,95%, sensitivitas sebesar 99,96%, spesifisitas sebesar 99,95%, koefisien jaccard sebesar 96,46% dan DSC sebesar 98,20% untuk masing masing citra liver. Penelitian ini menggunakan metode CNN U-Net hanya untuk melakukan segmentasi citra liver. Diharapkan untuk penelitian kedepannya, segmentasi citra liver dapat dilakukan dengan jaringan semantik untuk melatih node karena sangat bermanfaat terutama dalam bidang medis, dan untuk proses klasifikasi penyakit liver.

DAFTAR PUSTAKA

- Alalwan, N., Abozeid, A., ElHabshy, A. A. A., & Alzahrani, A. (2021). Efficient 3D Deep Learning Model for Medical Image Semantic Segmentation. *Alexandria Engineering Journal*, 60(1), 1231–1239. <https://doi.org/10.1016/j.aej.2020.10.046>
- Anter, A. M., & Hassenian, A. E. (2019). CT liver tumor segmentation hybrid approach using neutrosophic sets, fast fuzzy c-means and adaptive watershed algorithm. *Artificial Intelligence in Medicine*, 97(September), 105–117. <https://doi.org/10.1016/j.artmed.2018.11.007>
- Bilic, P., Christ, P. F., Vorontsov, E., Chlebus, G., Chen, H., Dou, Q., Fu, C.-W., Han, X., Heng, P.-A., Hesser, J., Kadoury, S., Konopczynski, T., Le, M., Li, C., Li, X., Lipkova, J., Lowengrub, J., Meine, H., Moltz, J. H., ... Menze, B. H. (2019). *The Liver Tumor Segmentation Benchmark (LiTS)*. 1–43. <http://arxiv.org/abs/1901.04056>
- Cai, J. (2019). Segmentation and Diagnosis of Liver Carcinoma Based on Adaptive Scale-Kernel Fuzzy Clustering Model for CT Images. *Journal of Medical Systems*, 43(11). <https://doi.org/10.1007/s10916-019-1459-2>
- Desiani, A., Zayanti, D. A., Primartha, R., Efriliyanti, F., & Andriani, N. A. C. (2021). Variasi Thresholding untuk Segmentasi Pembuluh Darah Citra Retina. *Jurnal Edukasi Dan Penelitian Informatika*, 7(2), 255–262.
- Es-Sabery, F., Hair, A., Qadir, J., Sainz-De-Abajo, B., Garcia-Zapirain, B., & Torre-Diez, I. (2021). Sentence-Level Classification Using Parallel Fuzzy Deep Learning Classifier. *IEEE Access*, 9(February), 17943–17985. <https://doi.org/10.1109/ACCESS.2021.3053917>
- Falatehan, A. I., Hidayat, N., & Brata, K. C. (2018). Sistem Pakar Diagnosis Penyakit Hati Menggunakan Metode Fuzzy Tsukamoto Berbasis Android. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer (J-PTIIK) Universitas Brawijaya*, 2(8), 2373–2381.

- Fernandez-Moral, E., Martins, R., Wolf, D., & Rives, P. (2018). A New Metric for Evaluating Semantic Segmentation: Leveraging Global and Contour Accuracy. *IEEE Intelligent Vehicles Symposium, Proceedings, 2018-June*(June), 1051–1056. <https://doi.org/10.1109/IVS.2018.8500497>
- Fikri, A. D. (2019). *Perbandingan Metode Dice Similarity dengan Cosine Similarity Menggunakan Query Expansion pada Pencarian Ayatul Ahkam dalam Terjemah Al-Qur'an Berbahasa Indonesia*. Universitas Islam Negeri Maulana Malik Ibrahim.
- Guo, T., Dong, J., & Li, H. (2017). Simple Convolutional Neural Network on Image Classification. *IEEE International Conference on Big Data Analysis*, 721–724.
- Han, L., Chen, Y., Li, J., Zhong, B., Lei, Y., & Sun, M. (2021). Liver segmentation with 2.5D perpendicular UNets. *Computers and Electrical Engineering*, 91(January), 107118. <https://doi.org/10.1016/j.compeleceng.2021.107118>
- Hasnain, M., Pasha, M. F., Ghani, I., Imran, M., Alzahrani, M. Y., & Budiarto, R. (2020). Evaluating Trust Prediction and Confusion Matrix Measures for Web Services Ranking. *IEEE Access*, 8, 90847–90861. <https://doi.org/10.1109/ACCESS.2020.2994222>
- He, X., Yu, Z., Wang, T., Lei, B., & Shi, Y. (2018). Dense deconvolution net: Multi path fusion and dense deconvolution for high resolution skin lesion segmentation. *Technology and Health Care*, 26(S1), S307–S316. <https://doi.org/10.3233/THC-174633>
- Kim, B., & Ye, J. C. (2018). Cycle-consistent adversarial network with polyphase U-Nets for liver lesion segmentation. *1st Conference on Medical Imaging with Deep Learning, Midl*, 1–3.
- Latifatul Khairiah, Tursina, T. R. (2017). Sistem Pakar Diagnosis Penyakit Hati Dengan Metode Dempster Shafer Berbasis Android. *Jurnal Coding Sistem Komputer Untan*, 5(2), 57–66.
- Li, X., Chen, H., Qi, X., Dou, Q., Fu, C. W., & Heng, P. A. (2018). H-DenseUNet: Hybrid Densely Connected UNet for Liver and Tumor Segmentation from CT Volumes. *IEEE Transactions on Medical Imaging*, 37(12), 2663–2674. <https://doi.org/10.1109/TMI.2018.2845918>
- Lian, S., Li, L., Lian, G., Xiao, X., Luo, Z., & Li, S. (2019). A Global and Local Enhanced Residual U-Net for Accurate Retinal Vessel Segmentation. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 14(8), 1–10. <https://doi.org/10.1109/tcbb.2019.2917188>
- Ma, J., Deng, Y., Ma, Z., Mao, K., & Chen, Y. (2021). A Liver Segmentation Method Based on the Fusion of VNet and WGAN. *Computational and Mathematical Methods in Medicine*, 2021. <https://doi.org/10.1155/2021/5536903>
- Mishra, S., Vanli, O. A., Huffer, F. W., & Jung, S. (2016). Regularized discriminant analysis for multi-sensor decision fusion and damage detection with Lamb waves. *Sensors and Smart Structures Technologies for Civil, Mechanical, and Aerospace Systems 2016*, 9803(850), 98032H. <https://doi.org/10.1117/12.2217959>
- Popat, V., Mahdinejad, M., Dalmau Cedeño, O. S., Naredo, E., & Ryan, C. (2020). GA-based U-Net architecture optimization applied to retina blood vessel segmentation. *IJCCI 2020 - Proceedings of the 12th International Joint Conference on Computational Intelligence, Ijcci*, 192–199. <https://doi.org/10.5220/0010112201920199>
- Pranata, T., Desiani, A., Suprihatin, B., Hanum, H., & Efriliyanti, F. (2022). *Segmentation of the Lungs on X-Ray Thorax Image with CNN Architecture U-Net*. 11(2), 101–111.
- Pravitasari, A. A., Iriawan, N., Almuhyar, M., Azmi, T., Irhamah, Fithriasari, K., Purnami, S. W., & Ferriastuti, W. (2020). UNet-VGG16 with transfer learning for MRI-based brain tumor segmentation. *Telkomnika (Telecommunication Computing Electronics and Control)*, 18(3), 1310–1318. <https://doi.org/10.12928/TELKOMNIKA.v18i3.14753>
- Qummar, S., Khan, F. G., Shah, S., Khan, A., Shamshirband, S., Rehman, Z. U., Khan, I. A., & Jadoon, W. (2019). A Deep Learning Ensemble Approach for Diabetic Retinopathy Detection. *IEEE Access*, 7, 150530–150539. <https://doi.org/10.1109/ACCESS.2019.2947484>
- Rela, M., Suryakari, N. R., & Reddy, P. R. (2020). Liver Tumor Segmentation and Classification: A Systematic Review. *Proceedings of 2020 IEEE-HYDCON International Conference on Engineering in the 4th Industrial Revolution, HYDCON 2020*, 21–26. <https://doi.org/10.1109/HYDCON48903.2020.9242757>
- Rosida, A. (2016). Pemeriksaan Laboratorium Penyakit Hati. *Berkala Kedokteran*, 12(1), 123. <https://doi.org/10.20527/jbk.v12i1.364>
- Saeedizadeh, N., Minaee, S., Kafieh, R., Yazdani, S., & Sonka, M. (2021). COVID TV-Unet: Segmenting COVID-19 chest CT images using connectivity imposed Unet. *Computer Methods and Programs in Biomedicine Update*, 1(March), 100007. <https://doi.org/10.1016/j.cmpbup.2021.100007>
- Shamsaldin, A., Fattah, P., Rashid, T., & Al-Salihi, N. (2019). A Study of The Convolutional Neural Networks Applications. *UKH Journal of Science and Engineering*, 3(2), 31–40. <https://doi.org/10.25079/ukhjse.v3n2y2019.pp31-40>

- Siddique, N., Paheding, S., Elkin, C. P., & Devabhaktuni, V. (2021). U-net and its variants for medical image segmentation: A review of theory and applications. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2021.3086020>
- Soomro, T. A., Afifi, A. J., Zheng, L., Soomro, S., Gao, J., Hellwich, O., & Paul, M. (2019). Deep Learning Models for Retinal Blood Vessels Segmentation: A Review. *IEEE Access*, 7, 71696–71717. <https://doi.org/10.1109/ACCESS.2019.2920616>
- Sule, O., & Viriri, S. (2020). Enhanced convolutional neural networks for segmentation of retinal blood vessel image. *2020 Conference on Information Communications Technology and Society, ICTAS 2020 - Proceedings*, 0–5. <https://doi.org/10.1109/ICTAS47918.2020.233996>
- Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., & Bray, F. (2021). Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries. *CA: A Cancer Journal for Clinicians*, 71(3), 209–249. <https://doi.org/10.3322/caac.21660>
- Triwoto, A. R., & Sardjono, T. A. (2015). *Rekonstruksi 3d Citra Magnetic Resonancy Imaging (Mri) Abdomen Untuk Identifikasi Polip Pada Saluran Pencernaan*. 404–410.
- Wang, M., & Deng, W. (2018). Deep visual domain adaptation: A survey. *Neurocomputing*, 312(April), 135–153. <https://doi.org/10.1016/j.neucom.2018.05.083>
- Xie, G. Sen, Zhang, X. Y., Yan, S., & Liu, C. L. (2017). Hybrid CNN and Dictionary-Based Models for Scene Recognition and Domain Adaptation. *IEEE Transactions on Circuits and Systems for Video Technology*, 27(6), 1263–1274. <https://doi.org/10.1109/TCSVT.2015.2511543>
- Zhou, W., Ma, X., & Zhang, Y. (2020). Research on Image Preprocessing Algorithm and Deep Learning of Iris Recognition. *Journal of Physics: Conference Series*, 1621(1). <https://doi.org/10.1088/1742-6596/1621/1/012008>
- Alalwan, N., Abozeid, A., ElHabshy, A. A. A., & Alzahrani, A. (2021). Efficient 3D Deep Learning Model for Medical Image Semantic Segmentation. *Alexandria Engineering Journal*, 60(1), 1231–1239. <https://doi.org/10.1016/j.aej.2020.10.046>
- Anter, A. M., & Hassenian, A. E. (2019). CT liver tumor segmentation hybrid approach using neutrosophic sets, fast fuzzy c-means and adaptive watershed algorithm. *Artificial Intelligence in Medicine*, 97(September), 105–117. <https://doi.org/10.1016/j.artmed.2018.11.007>
- Bilic, P., Christ, P. F., Vorontsov, E., Chlebus, G., Chen, H., Dou, Q., Fu, C.-W., Han, X., Heng, P.-A., Hesser, J., Kadoury, S., Konopczynski, T., Le, M., Li, C., Li, X., Lipková, J., Lowengrub, J., Meine, H., Moltz, J. H., ... Menze, B. H. (2019). *The Liver Tumor Segmentation Benchmark (LiTS)*. 1–43. <http://arxiv.org/abs/1901.04056>
- Cai, J. (2019). Segmentation and Diagnosis of Liver Carcinoma Based on Adaptive Scale-Kernel Fuzzy Clustering Model for CT Images. *Journal of Medical Systems*, 43(11). <https://doi.org/10.1007/s10916-019-1459-2>
- Desiani, A., Zayanti, D. A., Primartha, R., Efriliyanti, F., & Andriani, N. A. C. (2021). Variasi Thresholding untuk Segmentasi Pembuluh Darah Citra Retina. *Jurnal Edukasi Dan Penelitian Informatika*, 7(2), 255–262.
- Es-Sabery, F., Hair, A., Qadir, J., Sainz-De-Abajo, B., Garcia-Zapirain, B., & Torre-Diez, I. (2021). Sentence-Level Classification Using Parallel Fuzzy Deep Learning Classifier. *IEEE Access*, 9(February), 17943–17985. <https://doi.org/10.1109/ACCESS.2021.3053917>
- Falatehan, A. I., Hidayat, N., & Brata, K. C. (2018). Sistem Pakar Diagnosis Penyakit Hati Menggunakan Metode Fuzzy Tsukamoto Berbasis Android. *Jurnal Pengembangan Teknologi Informasi Dan Ilmu Komputer (J-PTIIK) Universitas Brawijaya*, 2(8), 2373–2381.
- Fernandez-Moral, E., Martins, R., Wolf, D., & Rives, P. (2018). A New Metric for Evaluating Semantic Segmentation: Leveraging Global and Contour Accuracy. *IEEE Intelligent Vehicles Symposium, Proceedings, 2018-June*(June), 1051–1056. <https://doi.org/10.1109/IVS.2018.8500497>
- Fikri, A. D. (2019). *Perbandingan Metode Dice Similarity dengan Cosine Similarity Menggunakan Query Expansion pada Pencarian Ayatul Ahkam dalam Terjemah Al-Qur'an Berbahasa Indonesia*. Universitas Islam Negeri Maulana Malik Ibrahim.
- Guo, T., Dong, J., & Li, H. (2017). Simple Convolutional Neural Network on Image Classification. *IEEE International Conference on Big Data Analysis*, 721–724.
- Han, L., Chen, Y., Li, J., Zhong, B., Lei, Y., & Sun, M. (2021). Liver segmentation with 2.5D perpendicular UNets. *Computers and Electrical Engineering*, 91(January), 107118. <https://doi.org/10.1016/j.compeleceng.2021.107118>
- Hasnain, M., Pasha, M. F., Ghani, I., Imran, M., Alzahrani, M. Y., & Budiarto, R. (2020). Evaluating Trust Prediction and Confusion Matrix Measures for Web Services Ranking. *IEEE Access*, 8, 90847–90861. <https://doi.org/10.1109/ACCESS.2020.2994222>

- He, X., Yu, Z., Wang, T., Lei, B., & Shi, Y. (2018). Dense deconvolution net: Multi path fusion and dense deconvolution for high resolution skin lesion segmentation. *Technology and Health Care*, 26(S1), S307–S316. <https://doi.org/10.3233/THC-174633>
- Kim, B., & Ye, J. C. (2018). Cycle-consistent adversarial network with polyphase U-Nets for liver lesion segmentation. *1st Conference on Medical Imaging with Deep Learning, Midl*, 1–3.
- Latifatul Khairiah, Tursina, T. R. (2017). Sistem Pakar Diagnosis Penyakit Hati Dengan Metode Dempster Shafer Berbasis Android. *Jurnal Coding Sistem Komputer Untan*, 5(2), 57–66.
- Li, X., Chen, H., Qi, X., Dou, Q., Fu, C. W., & Heng, P. A. (2018). H-DenseUNet: Hybrid Densely Connected UNet for Liver and Tumor Segmentation from CT Volumes. *IEEE Transactions on Medical Imaging*, 37(12), 2663–2674. <https://doi.org/10.1109/TMI.2018.2845918>
- Lian, S., Li, L., Lian, G., Xiao, X., Luo, Z., & Li, S. (2019). A Global and Local Enhanced Residual U-Net for Accurate Retinal Vessel Segmentation. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 14(8), 1–10. <https://doi.org/10.1109/tcbb.2019.2917188>
- Ma, J., Deng, Y., Ma, Z., Mao, K., & Chen, Y. (2021). A Liver Segmentation Method Based on the Fusion of VNet and WGAN. *Computational and Mathematical Methods in Medicine*, 2021. <https://doi.org/10.1155/2021/5536903>
- Mishra, S., Vanli, O. A., Huffer, F. W., & Jung, S. (2016). Regularized discriminant analysis for multi-sensor decision fusion and damage detection with Lamb waves. *Sensors and Smart Structures Technologies for Civil, Mechanical, and Aerospace Systems 2016*, 9803(850), 98032H. <https://doi.org/10.1117/12.2217959>
- Popat, V., Mahdinejad, M., Dalmau Cedeño, O. S., Naredo, E., & Ryan, C. (2020). GA-based U-Net architecture optimization applied to retina blood vessel segmentation. *IJCCI 2020 - Proceedings of the 12th International Joint Conference on Computational Intelligence, Ijcci*, 192–199. <https://doi.org/10.5220/0010112201920199>
- Pranata, T., Desiani, A., Suprihatin, B., Hanum, H., & Efriliyanti, F. (2022). Segmentation of the Lungs on X-Ray Thorax Image with CNN Architecture U-Net. 11(2), 101–111.
- Pravitasari, A. A., Iriawan, N., Almuhayar, M., Azmi, T., Irhamah, Fithriasari, K., Purnami, S. W., & Ferriastuti, W. (2020). UNet-VGG16 with transfer learning for MRI-based brain tumor segmentation. *Telkomnika (Telecommunication Computing Electronics and Control)*, 18(3), 1310–1318. <https://doi.org/10.12928/TELKOMNIKA.v18i3.14753>
- Qummar, S., Khan, F. G., Shah, S., Khan, A., Shamshirband, S., Rehman, Z. U., Khan, I. A., & Jadoon, W. (2019). A Deep Learning Ensemble Approach for Diabetic Retinopathy Detection. *IEEE Access*, 7, 150530–150539. <https://doi.org/10.1109/ACCESS.2019.2947484>
- Rela, M., Suryakari, N. R., & Reddy, P. R. (2020). Liver Tumor Segmentation and Classification: A Systematic Review. *Proceedings of 2020 IEEE-HYDCON International Conference on Engineering in the 4th Industrial Revolution, HYDCON 2020*, 21–26. <https://doi.org/10.1109/HYDCON48903.2020.9242757>
- Rosida, A. (2016). Pemeriksaan Laboratorium Penyakit Hati. *Berkala Kedokteran*, 12(1), 123. <https://doi.org/10.20527/jbk.v12i1.364>
- Saeedizadeh, N., Minaee, S., Kafieh, R., Yazdani, S., & Sonka, M. (2021). COVID TV-Unet: Segmenting COVID-19 chest CT images using connectivity imposed Unet. *Computer Methods and Programs in Biomedicine Update*, 1(March), 100007. <https://doi.org/10.1016/j.cmpbup.2021.100007>
- Shamsaldin, A., Fattah, P., Rashid, T., & Al-Salihi, N. (2019). A Study of The Convolutional Neural Networks Applications. *UKH Journal of Science and Engineering*, 3(2), 31–40. <https://doi.org/10.25079/ukhjse.v3n2y2019.pp31-40>
- Siddique, N., Paheding, S., Elkin, C. P., & Devabhaktuni, V. (2021). U-net and its variants for medical image segmentation: A review of theory and applications. *IEEE Access*. <https://doi.org/10.1109/ACCESS.2021.3086020>
- Soomro, T. A., Afifi, A. J., Zheng, L., Soomro, S., Gao, J., Hellwich, O., & Paul, M. (2019). Deep Learning Models for Retinal Blood Vessels Segmentation: A Review. *IEEE Access*, 7, 71696–71717. <https://doi.org/10.1109/ACCESS.2019.2920616>
- Sule, O., & Viriri, S. (2020). Enhanced convolutional neural networks for segmentation of retinal blood vessel image. *2020 Conference on Information Communications Technology and Society, ICTAS 2020 - Proceedings*, 0–5. <https://doi.org/10.1109/ICTAS47918.2020.233996>
- Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., & Bray, F. (2021). Global Cancer Statistics 2020: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries. *CA: A Cancer Journal for Clinicians*, 71(3), 209–249. <https://doi.org/10.3322/caac.21660>
- Triwoto, A. R., & Sardjono, T. A. (2015). Rekonstruksi 3d Citra Magnetic Resonancy Imaging (Mri) Abdomen Untuk Identifikasi Polip Pada Saluran Pencernaan. 404–410.

- Wang, M., & Deng, W. (2018). Deep visual domain adaptation: A survey. *Neurocomputing*, 312(April), 135–153. <https://doi.org/10.1016/j.neucom.2018.05.083>
- Xie, G. Sen, Zhang, X. Y., Yan, S., & Liu, C. L. (2017). Hybrid CNN and Dictionary-Based Models for Scene Recognition and Domain Adaptation. *IEEE Transactions on Circuits and Systems for Video Technology*, 27(6), 1263–1274. <https://doi.org/10.1109/TCSVT.2015.2511543>
- Zhou, W., Ma, X., & Zhang, Y. (2020). Research on Image Preprocessing Algorithm and Deep Learning of Iris Recognition. *Journal of Physics: Conference Series*, 1621(1). <https://doi.org/10.1088/1742-6596/1621/1/012008>